

ANALYSE DES PERFORMANCES DES ÉQUIPES NATIONALES

ayant participé à la Coupe du Monde de la FIFA
jusqu'en 2022

ENCADRÉ PAR :
EL HANNOUN Wafaa

REALISÉ PAR :
ZRIOUIL Souad



Introduction	5
Analyse des Correspondances factorielle -Théorie.....	6
1. Introduction.....	6
2. Les étapes d'application de l'AFC	6
Préparation des données.....	9
1. Introduction.....	9
2. Collection de données	9
3. Nettoyage des données.....	12
4. Les Technologie Utiliser Pour Appliquer AFC	13
Application d'AFC	14
1. Introduction.....	14
2. Appliquer Par R	14
2.1 Chargement des données.....	14
2.2 Visualiser le tableau de contingence en diagramme a bulle	14
2.3 Test de khi2.....	16
2.4 Calculer l'AFC	17
2.5 Valeurs propres variances	17
2.6 Le graphique des valeurs propres avec une droite en pointillée	18
2.7 Le biplot des lignes et des colonnes	19
2.8 Graphique Des Points Lignes	19
2.8.1 Les coordonnées des lignes	20
2.8.2 Qualité de représentation des lignes	21
2.9 Graphique Des Points Colonnes	22
2.9.1 Les coordonnées des colonnes	23
2.9.2 Qualité de représentation des colonnes	23
3. Appliquer Par Python	24
3.1 Charger et afficher les donnees.....	24
3.2 Test de khi2.....	25
3.3 AFC en python	26
3.4 Les valeurs propres.....	26
3.5 Résultat des lignes.....	27
3.5.1 Les Coordonnées des points lignes	27
3.5.2 Les Contribution des points lignes	28
3.5.3 Les qualités des points lignes.....	29
3.6 Résultat des colonnes.....	29
3.6.1 Les Coordonnées des points colonnes	29
3.6.2 Les Contributions des points colonnes	30
3.6.3 Les qualités des points colonnes.....	30
3.7 Représentation des points de lignes et de colonnes	30
4. Appliquer par Excell.....	31
4.1 L'utilisation d'Excel	31
4.2 Test de khi2.....	32
4.3 Les valeurs propres.....	32
4.4 Scree plot.....	33

4.5	Résultats pour lignes	33
4.5.1	Poids, distances et distances quadratiques a l'origine, inerties et inerties relatives	33
4.5.2	Les coordonnées des lignes	35
4.5.3	Les contributions des lignes	36
4.6	Résultat pour les colonnes	36
4.6.1	Poids, distances et carrés des distances à l'origine, inerties et inerties relatives (colonnes)	36
4.6.2	Les coordonnées des colonnes	36
4.6.3	Les contributions des colonnes	37
4.7	Graphique symétrique.....	37
1.	<i>Compréhension des axes</i>	39
2.	<i>Contribution des lignes</i>	40
3.	<i>Contribution des colonnes</i>	40
4.	<i>Qualité de représentation des lignes</i>	41
5.	<i>Qualité de représentation des colonnes</i>	41
6.	<i>Graphe des points de lignes et de colonnes</i>	42
Conclusion		44

Figure 1: le site web cible "www.wikipedia.org"	9
Figure 2: Affichage de la page Web dans WebHarvey	10
Figure 3: Extraction des données des équipes	11
Figure 4: Exporter les données dans un fichier Excel	11
Figure 5:Nettoyage des données(code).....	12
Figure 6:Fichier de données nettoyées	12
Figure 7:Les technologies utilisées	13
Figure 8:charger et afficher les données(code)	14
Figure 9:Afficher les données à l'aide de la fonction View()	14
Figure 10:code le tableau de contingence en diagramme a bulle.....	15
Figure 11:tableau de contingence en diagramme a bulle	15
Figure 12:le graphique corplot (code).....	15
Figure 13:tableau de contingence en diagramme a bulle selon effectif	16
Figure 14:Test de chi2 (code).....	16
Figure 15:Résultat du test du khi2	16
Figure 16:Calculer L'AFC (code)	17
Figure 17:Resultat de AFC.....	17
Figure 18:valeurs propres (code).....	17
Figure 19:Affichage des valeurs propres	18
Figure 20:fonction fviz_eig() (code).....	18
Figure 21:Le graphe des valeurs propres.....	18
Figure 22:fonction fviz_ca_biplot (code).....	19
Figure 23:le biplot de lignes et colonnes.....	19
Figure 24:les coordonnées des points lignes (code)	19
Figure 25:Correspondence Analysis - Results for rows.....	20
Figure 26:Les coordonnes des lignes (code).....	20
Figure 27:Affichage les coordonnes des lignes.....	20
Figure 28:fviz_ca_row (code)	20
Figure 29:Représentation des lignes	21
Figure 30:Qualité de représentation des lignes(code)	21
Figure 31:Affichage La qualite des points lignes	21
Figure 32:Qualité de représentation des lignes (code)	22
Figure 33:Afficher le graphique des points lignes colorés.....	22
Figure 34::Obtenir les coordonnées des points colonnes (code)	22
Figure 35:Correspondence Analysis - Results for columns.....	22
Figure 36:Les coordonnes des colonnes.....	23
Figure 37:le graphique des points colonnes (code).....	23
Figure 38:la Représentation des colonnes	23
Figure 39:Qualité de représentation des colonnes	24
Figure 40:Afficher le graphique des points colonnes (code)	24
Figure 41:Qualite de representation	24
Figure 42:Importation des packages et des données(code).....	25
Figure 43:Les donnees affichées	25
Figure 44:Test de khi2(code)	25
Figure 45: Résultat du test khi2	25
Figure 46:Application de AFC (code)	26
Figure 47: Résultat de l'AFC.....	26
Figure 48:les valeur propres(code).....	26

Figure 49: Affichage des valeurs propres.....	27
Figure 50: la fonction plot_eigenvalues(code)	27
Figure 51:le graphe des valeurs propres	27
Figure 52:L'objet row_coord (code)	27
Figure 53:Les coordonnees des points lignes.....	28
Figure 54:L'objet row_contrib_ (code)	28
Figure 55:Les Contribution des points lignes	28
Figure 56:L'objet row_cos2 (code)	29
Figure 57:Les qualites des points lignes	29
Figure 58:L'objet col_coord_ (code).....	29
Figure 59: : Les coordonnees des points lignes	29
Figure 60: L'objet col_contrib_ (code).....	30
Figure 61:Les contributions des points colonnes	30
Figure 62:Les qualites des points colonnes (code).....	30
Figure 63:Les qualites des points colonnes	30
Figure 64:la fonction mapping() (code)	30
Figure 65: Représentation simultanée	31
Figure 66:L'UTILISATION DE EXCEL	31
Figure 67:la boîte de dialogue CA.....	32
Figure 68:Test de khi2.....	32
Figure 69:Les valeurs propres par Excel	33
Figure 70:Scree plot.....	33
Figure 71:la Distance et le poids pour les lignes	34
Figure 72:Résultats pour les lignes	35
Figure 73:Les coordonnees des lignes.....	35
Figure 74:Contributions (lignes)	36
Figure 75:La distance et le poids des colonnes	36
Figure 76:Les coordonnees des colonnes.....	37
Figure 77:Les contrubutions des colonnes	37
Figure 78:Graphique symétrique.....	38
Figure 79:Contribution des lignes.....	40
Figure 80:Contribution des colonnes	40

Introduction

L'analyse de données joue un rôle crucial dans les prises de décision stratégiques dans divers secteurs. Ce projet vise à explorer les applications de l'Analyse de Correspondance Factorielle (ACF) en examinant un ensemble de données portant sur les performances des équipes nationales ayant participé à la Coupe du Monde de la FIFA jusqu'en 2022. Ce jeu de données complexe offre une opportunité unique pour découvrir des tendances cachées et des relations subtiles.

Dans cette étude, nous adoptons une approche méthodique basée sur l'ACF en raison de sa capacité à révéler les structures sous-jacentes dans des ensembles de données structurées. L'ACF, axée sur la détection de concepts et de relations entre eux, s'avère particulièrement appropriée pour l'analyse de données complexes où les interactions entre les variables sont nombreuses et complexes.

L'utilisation de l'Analyse de Correspondance Factorielle dans cette étude représente une approche novatrice pour l'analyse de données complexes, offrant une vision approfondie des performances des équipes de football. Notre objectif est d'identifier des tendances significatives et des schémas sous-jacents souvent invisibles à l'œil nu. Cette approche analytique, soutenue par une solide expertise en langages de programmation tels que R et Python, ainsi que l'utilisation d'outils spécialisés comme XLSTAT, promet des insights précieux pour des applications pratiques dans le domaine du sport.

Analyse des Correspondances factorielle -Théorie

1. Introduction

L'Analyse des Correspondances est une technique statistique multivariée qui est conceptuellement similaire à l'Analyse en Composantes Principales, mais s'applique à des données catégorielles plutôt qu'à des données continues. Cette technique est conçue pour analyser des tableaux contenant une certaine mesure de correspondance entre les lignes et les colonnes.

En général, l'Analyse des Correspondances travaille avec des tableaux de fréquences bidirectionnels ou des tableaux de contingence où les lignes sont les catégories d'une variable et les colonnes sont les catégories d'une autre variable. L'objectif principal de cette analyse multivariée est de visualiser dans un graphique de dispersion bidimensionnel les relations cachées entre les catégories de chaque variable.

2. Les étapes d'application de l'AFC

✓ Étape 1 : Construction du tableau de données

L'AFC nécessite un tableau de données croisées appelé "tableau de contingence". Ce tableau doit être construit à partir des données brutes, en croisant les valeurs de chaque variable.

	Variable 1	Variable 2	...	Variable p
Individu 1	n_{11}	n_{12}	...	n_{1p}
Individu 2	n_{21}	n_{22}	...	n_{2p}
...	...	...	...	...
Individu n	n_{n1}	n_{n2}	...	n_{np}

Chaque n_{ij} représente le nombre d'individus ayant à la fois la valeur i pour la variable 1 et la valeur j pour la variable 2.

✓ Étape 2 : Calcul de la distance de khi-deux

La distance de khi-deux est une mesure de la différence entre les observations et les fréquences attendues sous l'hypothèse d'indépendance entre les variables. Elle est utilisée pour mesurer la similitude entre deux variables. La formule de la distance de khi-deux est la suivante :

$$d^2_{ij} = \sum_{k=1}^p \frac{(n_{ik}n_{jk})^2}{(n_{i.}n_{.k}n_{j.}n_{.k})}$$

Où $n_{j.}$ est la somme des effectifs de la ligne j , $n_{.k}$ est la somme des effectifs de la colonne k et $n_{..}$ est la somme totale des effectifs du tableau.

✓ Étape 3 : Calcul de la matrice des distances

La matrice des distances est une matrice carrée qui mesure les distances entre chaque paire de variables. Elle est calculée en utilisant la distance de khi-deux entre chaque paire de variable.

✓ Étape 4 : Calcul des cosinus carrés et des contributions

Les cosinus carrés mesurent l'association entre chaque variable et chaque axe factoriel. Ils sont calculés en utilisant la formule suivante :

$$\cos_{ij}^2 = \frac{f_{ij}^2}{r_i c_j}$$

Où f_{ij} est la fréquence observée de la variable i pour la catégorie j , r_i est la somme des fréquences de la variable i et c_j est la somme des fréquences de la catégorie j .

Les contributions mesurent l'importance de chaque variable pour l'axe factoriel correspondant. Elles sont calculées en utilisant la formule suivante :

$$\text{contribution}_{ij} = \frac{\cos_{ij}^2}{\lambda_i}$$

Où λ_i est la valeur propre de l'axe factoriel j . Les contributions sont exprimées en pourcentage et indiquent la part de la variance expliquée par chaque variable sur l'axe factoriel correspondant.

Les cosinus carrés et les contributions sont des indicateurs importants pour interpréter les résultats de l'AFC et sélectionner les variables les plus pertinentes pour chaque axe factoriel.

✓ Étape 5 : Calcul des valeurs propres

Les valeurs propres sont des mesures de l'importance de chaque axe factoriel pour expliquer la variation totale des données.

Les valeurs propres sont calculées à partir des cosinus carrés des variables sur chaque axe factoriel. La formule de calcul est la suivante :

$$\lambda_j = \sum_{i=1}^n \cos_{ij}^2$$

Où λ_j est la valeur propre de l'axe factoriel j et $\cos_{ij}^2$ est le carré du cosinus de l'angle formé entre la variable i et l'axe factoriel j . Les valeurs propres sont ordonnées de manière décroissante, et l'axe factoriel qui a la plus grande valeur propre est appelé le premier axe factoriel.

✓ Étape 6 : Construction du graphique

Le graphique de l'AFC est un nuage de points qui représente les individus et les variables dans un espace de dimension réduite. Les axes du graphique sont les axes factoriels, et les points

sont placés en fonction de leurs coordonnées sur ces axes. Les points qui sont proches les uns des autres ont des profils similaires.

Pour construire le graphique de l'AFC, on utilise les coordonnées factorielles des individus et des variables qui ont été calculées à l'étape 4. Les individus sont représentés par des cercles, et les variables sont représentées par des flèches qui indiquent leur contribution à chaque axe factoriel.

On peut également colorer les cercles ou les flèches en fonction d'une variable supplémentaire pour visualiser la relation entre cette variable et les axes factoriels.

Préparation des données

1. Introduction

La collecte et la préparation des données sont une étape cruciale dans tout projet de recherche, car elles impliquent la collecte et l'organisation des données qui seront utilisées pour l'analyse. Dans cette section, nous décrirons les méthodes que nous avons utilisées pour collecter et préparer les données pour notre étude sur les résultats des équipes nationales ayant participé à la Coupe du Monde de la FIFA jusqu'en 2022.

2. Collection de données

Dans mon projet de recherche, je n'ai pas été en mesure de trouver un jeu de données disponible qui répondait à mes besoins. En conséquence, j'ai décidé de collecter les données moi-même en utilisant une technique appelée **Web Scrapping**. J'ai utilisé un outil appelé WebHarvy, qui est un web scraper.

Après avoir mené mes recherches, j'ai découvert le site "wikipedia.org", une importante source d'informations en ligne regorgeant de données pertinentes pour mon étude. Ce site compile de nombreuses informations sur les records et les statistiques de la Coupe du Monde de la FIFA. Ces données seront d'une grande utilité dans la conduite de mon analyse.

Records et statistiques de la Coupe du Monde de la FIFA 30 langues

Article [Parler](#) Lire Modifier Voir l'historique Outils

Un article de Wikipédia, l'encyclopédie libre

Depuis la [Coupe du Monde de la FIFA 2022](#), 80 équipes nationales ont participé à la finale de la [Coupe du Monde de la FIFA](#). ^[1] Le [Brésil](#) est la seule équipe à avoir participé aux 22 tournois à ce jour, l'[Allemagne](#) ayant participé à 20, l'[Italie](#) et l'[Argentine](#) à 18 et le [Mexique](#) à 17. ^[2] Huit nations ont remporté le tournoi. Les premiers gagnants en 1930 étaient l'[Uruguay](#) ; les champions actuels sont l'[Argentine](#). La nation la plus titrée est le [Brésil](#), qui a remporté la coupe à cinq reprises. ^[3] Cinq équipes ont participé à la [finale de la Coupe du Monde de la FIFA](#) sans gagner, ^[4] tandis que douze autres sont apparues en demi-finale. ^[5]

Liste des tournois

Année	Hôte	Champions	Entraîneur gagnant	Meilleur(s) buteur(s)	Prix du meilleur joueur	Source
1930	Uruguay	Uruguay	Alberto Suppici	Guillermo Stabile (8)		[6]
1934	Italie	Italie	Vittorio Pozzo	Oldřich Nejedlý (5)		[7]
1938	France	Italie	Vittorio Pozzo	Léonidas (7)		[8]
1950	Brésil	Uruguay	Juan Lopez	Adémir (9)		[9]
1954	Suisse	Allemagne de l'Ouest	Sepp	Sándor Kocsis (11)		[dix]

Figure 1: le site web cible "www.wikipedia.org"

La prochaine étape consiste à afficher la page dans WebHarvy afin d'identifier les données que nous souhaitons extraire.




Figure 2: Affichage de la page Web dans WebHarvy

Voici les données que nous avons pu extraire :

- Rank : Le classement de l'équipe.
- Team : Le nom de l'équipe de football.
- Part : Le nombre de fois que l'équipe a participé à la Coupe du Monde de la FIFA.
- Pld : Le nombre total de matchs joués par l'équipe.
- W : Le nombre de matchs remportés par l'équipe.
- D : Le nombre de matchs nuls (matchs terminant sur un score égal) de l'équipe.
- L : Le nombre de matchs perdus par l'équipe.
- GF : Le nombre total de buts marqués par l'équipe (goals for).
- GA : Le nombre total de buts encaissés par l'équipe (goals against).
- GD : La différence de buts (goal difference), calculée en soustrayant les buts encaissés des buts marqués.
- Pts : Le total des points accumulés par l'équipe, calculé selon le système de points de la FIFA où 3 points sont attribués pour une victoire, 1 point pour un match nul et 0 point pour une défaite.

Dans mon analyse, j'ai choisi de considérer deux variables qualitatives principales : les équipes participantes et les résultats de leurs matchs, classés en victoires, matchs nuls ou défaites. Ces variables sont cruciales pour évaluer la performance des équipes de football tout au long de la Coupe du Monde de la FIFA.

✓ Exécution du scraping :

Après avoir cliqué sur le bouton "Start" ou "Scrape" dans WebHarvy pour lancer le processus de scraping, je peux commencer à définir les données que je souhaite extraire. Cela implique généralement l'identification et la sélection des éléments spécifiques sur la page Web à partir desquels je souhaite extraire les données.




Figure 3: Extraction des données des équipes

Une fois que j'ai sélectionné toutes les données que je souhaite extraire, je peux passer à l'étape suivante en cliquant sur le bouton "Stop" pour arrêter le processus de scraping. Cela indique à WebHarvy que j'ai terminé de définir les modèles de données et que je suis prêt à passer à l'étape suivante, qui consiste à exporter les données dans un fichier Excel.




Figure 4: Exporter les données dans un fichier Excel

3. Nettoyage des données

Comme vous pouvez le constater, il y a des lignes dans les données qui doivent être supprimées, et dans certains noms d'équipe, il y a des accolades qui doivent être supprimées. Nous devons donc nettoyer ces données et créer un nouveau fichier CSV. Pour cela, j'ai créé ce script Python:

```
#Importation des bibliothèques
import pandas as pd
from fanalysis.ca import CA
import numpy as np
import matplotlib.pyplot as plt

# Chargement des données à partir d'un fichier Excel
data = pd.read_excel("C:\AnalyseD\Coupe_du_monde.xlsx")

# Supprimer les lignes après la ligne 80
data = data.drop(index=range(80, len(data)))

# Nettoyer la colonne "Team" en supprimant les accolades et leur contenu
data['équipe national'] = data['équipe national'].str.replace(r'\s*\[.*?\]\s*', '', regex=True)

# Enregistrer les données nettoyées dans un nouveau fichier Excel
data.to_excel("C:\AnalyseD\donnees_nettoyees_Coupe_du_monde.xlsx", index=False)
```

Figure 5:Nettoyage des données(code)

Le fichier de sortie : donnees_nettoyees_Coupe_du_monde.xlsx.

1	équipe national	Victoires	matches nuls	défaites
2	Brazil	76	19	19
3	Germany	68	21	23
4	Argentina	47	17	24
5	Italy	45	21	17
6	France	39	14	20
7	England	32	22	20
8	Spain	31	17	19
9	Netherlands	30	14	11
10	Uruguay	25	13	21
11	Belgium	21	10	20
12	Sweden	19	13	19
13	Russia	19	10	16
14	Mexico	17	15	28
15	Serbia	18	9	22
16	Portugal	17	6	12
17	Poland	17	6	15
18	Switzerland	14	8	19
19	Hungary	15	3	14

Figure 6:Fichier de données nettoyées

4. Les Technologie Utiliser Pour Appliquer AFC

Dans le chapitre suivant, nous allons essayer d'écrire le code pour chacune des applications suivantes. Nous commencerons par expliquer comment nous l'avons fait, en commentant chaque code, puis nous l'appliquerons aux mêmes données sur lesquelles nous avons travaillé dans ce projet. Ensuite, nous ferons une petite comparaison entre les applications.



Figure 7: Les technologies utilisées

Application d'AFC

1. Introduction

Dans ce chapitre, nous appliquerons l'Analyse Factorielle des Correspondances (AFC) en utilisant les langages de programmation R, Python, ainsi que Microsoft Excel. Nous utiliserons l'ensemble des données collectées dans le deuxième chapitre de notre étude.

2. Appliquer Par R

2.1 Chargement des données

```
library(readxl)
# Charger les données depuis le fichier Excel
donnees <-
as.data.frame(read_excel("C:/AnalyseD/donnees_nettoyees_Coupe_du_monde.xlsx"))
# Afficher les données dans une nouvelle fenêtre
View(donnees)
```

Figure 8: charger et afficher les données(code)

Ce script en R utilise la bibliothèque "**readxl**" pour importer des données à partir d'un fichier Excel. Les données sont ensuite transformées en un dataframe à l'aide de la fonction '**as.data.frame()**'. Enfin, pour visualiser les données dans une nouvelle fenêtre, la fonction '**View()**' est utilisée.

	équipe national	Victoires	matchs nuls	défaites
1	Brazil	76	19	19
2	Germany	68	21	23
3	Argentina	47	17	24
4	Italy	45	21	17
5	France	39	14	20
6	England	32	22	20
7	Spain	31	17	19
8	Netherlands	30	14	11
9	Uruguay	25	13	21
10	Belgium	21	10	20
11	Sweden	19	13	19
12	Russia	19	10	16
13	Mexico	17	15	28
14	Serbia	18	9	22
15	Portugal	17	6	12
16	Poland	17	6	15
17	Switzerland	14	8	19
18	Hungary	15	3	14
19	Croatia	13	8	9

Figure 9: Afficher les données à l'aide de la fonction View()

2.2 Visualiser le tableau de contingence en diagramme a bulle

Étant donné la grande taille du tableau de contingence, il est aisé de visualiser et interpréter les profils des lignes et des colonnes avec seulement 20 lignes affichées.

```

library("gplots")

# Convertir les donnees en tant que table
dt <- as.table(as.matrix(donnees[1:20, ])) # Sélectionne les 20 premières lignes

# Créer le balloonplot avec les 20 premières lignes
balloonplot(t(dt),
  main = "Coupe du monde",
  xlab = "",
  ylab = "",
  label = FALSE,
  show.margins = FALSE)

```

Figure 10:code le tableau de contingence en diagramme a bulle

Le résultat de l'exécution :




Figure 11:tableau de contingence en diagramme a bulle

Le tableau de contingence peut être visualisé en utilisant C :

```

library(corrplot)

# Générer une palette de couleurs
col <- colorRampPalette(c("blue", "yellow", "red"))(100)

# Afficher le graphique corrplot
corrplot(dt,
  is.corr = FALSE,
  method = "circle",
  bg = "white",
  col = col
)

```

Figure 12:le graphique corrplot (code)

Donne le résultat suivant :




Figure 13: tableau de contingence en diagramme a bulle selon effectif

2.3 Test de khi2

Pour interpréter l'analyse des correspondances, la première étape à faire c'est de savoir où il y a une dépendance entre les lignes et les colonnes. En peut utiliser le test de khi-2 : en fait il permet de trouver la probabilité que les deux variables d'un tableau de contingence soient indépendantes, c'est-à-dire qu'il n'y a pas une liaison entre les modalités en ligne les modalités en colonne.

```
#Test Chi2
chisq <- chisq.test(donnees)
chisq
```

Figure 14: Test de chi2 (code)

Le résultat de l'exécution :

Pearson's Chi-squared test

```
data: donnees
X-squared = 317.79, df = 158, p-value = 8.198e-13
```

Figure 15: Résultat du test du khi2

Les résultats du test du khi-2 indiquent un chi-deux élevé de 317.79 avec 158 degrés de liberté, et une valeur de p très faible de 8.198e-13. Ces résultats nous conduisent à rejeter l'hypothèse

nulle d'indépendance entre les variables. En d'autres termes, il existe une association significative entre les modalités en ligne et les modalités en colonne dans le tableau de contingence analysé, ce qui souligne l'existence d'une liaison importante entre ces variables.

2.4 Calculer l'AFC

```
#Calculer l'afc
library(FactoMineR)
CA(donnees, graph = FALSE)
afc <- CA(donnees, graph = FALSE)
```

Figure 16: Calculer L'AFC (code)

Le code R utilise la bibliothèque « FactoMineR » pour effectuer une Analyse Factorielle des Correspondances (AFC) sur un jeu de données appelé « donnees ». La fonction « CA() » est utilisée pour réaliser cette analyse. Le paramètre `graph` indique si un graphique doit être généré ou non pour visualiser les résultats de l'analyse.

Le résultat de la fonction CA () est une liste comprenant :

```
> CA(donnees, graph = FALSE)
**Results of the Correspondence Analysis (CA)**
The row variable has 80 categories; the column variable has 3 categories
The chi square of independence between the two variables is equal to 317.7894 (p-value = 8.197
982e-13 ).
*The results are available in the following objects:
```

name	description
1 "\$eig"	"eigenvalues"
2 "\$col"	"results for the columns"
3 "\$col\$coord"	"coord. for the columns"
4 "\$col\$cos2"	"cos2 for the columns"
5 "\$col\$contrib"	"contributions of the columns"
6 "\$row"	"results for the rows"
7 "\$row\$coord"	"coord. for the rows"
8 "\$row\$cos2"	"cos2 for the rows"
9 "\$row\$contrib"	"contributions of the rows"
10 "\$call"	"summary called parameters"
11 "\$call\$marge.col"	"weights of the columns"
12 "\$call\$marge.row"	"weights of the rows"

Figure 17: Resultat de AFC

2.5 Valeurs propres variances

L'examen des valeurs propres permet de déterminer le nombre d'axes principaux à considérer. Les valeurs propres correspondent à la quantité d'informations retenue par chaque axe. Elles sont grandes pour le premier axe et petites pour l'axe suivant. Les valeurs propres et la proportion de variance expliquée (capturée) par les différents axes peuvent être extraites à l'aide du code suivant :

```
library(factoextra)
# Calculer les valeurs propres
val_pro <- get_eigenvalue(afc)
print(val_pro)
```

Figure 18: valeurs propres (code)

Le résultat de l'exécution :

```
> print(val_pro)
      eigenvalue variance.percent cumulative.variance.percent
Dim.1 0.028799864       78.71197       78.71197
Dim.2 0.007789061       21.28803      100.00000
```

Figure 19:Affichage des valeurs propres

2.6 Le graphique des valeurs propres avec une droite en pointillée

Une autre méthode pour déterminer le nombre de dimensions est de regarder le graphique des valeurs propres (scree plot), ordonnées de la plus grande à la plus petite valeur. Le nombre d'axes est déterminé par le point au-delà duquel les valeurs propres restantes sont toutes relativement petites et de tailles comparables. Le graphique des valeurs propres peut être produit à l'aide de la fonction `fviz_eig()` ou `fviz_screplot()` [package `factoextra`].

```
library(factoextra)
# Visualiser le graphique des valeurs
propres
fviz_eig(afc, addlabels = TRUE)
```

Figure 20:fonction `fviz_eig()` (code)

Donne le résultat suivant :




Figure 21:Le graphe des valeurs propres

2.7 Le biplot des lignes et des colonnes

La fonction `fviz_ca_biplot()` [package `factoextra`] peut être utilisée pour dessiner le **biplot** des lignes et des colonnes. Dans le graphique les lignes sont représentées par des points bleus et des colonnes par des triangles rouges.

La distance entre les points lignes ou entre les points colonnes donne une mesure de leur similitude (ou dissemblance). Les points lignes avec un profil similaire sont proches sur le graphique. Il en va de même pour les points colonnes.

```
# Création d'un biplot avec fviz_ca_biplot
fviz_ca_biplot(afc, repel = TRUE, col.row =
"blue", col.col = "red")
```

Figure 22: fonction `fviz_ca_biplot` (code)

Donne le résultat suivant :




Figure 23: le biplot de lignes et colonnes

2.8 Graphique Des Points Lignes

La fonction `get_ca_row()` [package `factoextra`] est utilisée pour extraire les résultats pour les lignes. Cette fonction renvoie une liste contenant les coordonnées, les cos2 et les contributions des lignes :

```
# Obtenir les coordonnées des points lignes
coords_rows <- get_ca_row(afc)
coords_rows
```

Figure 24: les coordonnées des points lignes (code)

Donner le résultat suivant :

```
> coords_rows
Correspondence Analysis - Results for rows
=====
      Name      Description
1 "$coord"  "Coordinates for the rows"
2 "$cos2"   "Cos2 for the rows"
3 "$contrib" "contributions of the rows"
4 "$inertia" "Inertia of the rows"
```

Figure 25:Correspondence Analysis - Results for rows.

2.8.1 Les coordonnées des lignes

Le code R ci-dessous affiche les coordonnées de chaque point ligne pour chacune des dimensions :

```
# Obtenir les coordonnées des points lignes pour chaque dimension
head(coords_rows$coord)
```

Figure 26:Les coordonnées des lignes (code)

Donne le résultat suivant :

```
> head(coords_rows$coord)
      Dim 1      Dim 2
Brazil    0.5705220 -0.12653599
Germany   0.4588030 -0.07714722
Argentina 0.2995933 -0.06463364
Italy     0.3843861  0.08021599
France    0.2983891 -0.06801966
England   0.1849561  0.18548390
```

Figure 27:Affichage les coordonnées des lignes

Utilisez la fonction `fviz_ca_row()` [dans `factoextra`] pour visualiser uniquement les points lignes :

```
# Afficher le graphique des points lignes (individus)
fviz_ca_row(afc, col.row = "blue")
```

Figure 28:fviz_ca_row (code)

Donne le résultat suivant :




Figure 29:Representation des lignes

2.8.2 Qualité de représentation des lignes

Les cosinus carrés indiquent la qualité de représentation de chaque individu dans l'espace factoriel. Plus la valeur du cosinus carré est proche de 1, plus l'individu est bien représenté sur cette dimension. Un cosinus carré proche de 0 indique que l'individu n'est pas bien représenté sur cette dimension.

Le cos2 mesure le degré d'association entre les lignes / colonnes et un axe particulier. Le cos2 des points lignes peut être extrait comme suit :




Figure 30:Qualité de représentation
des lignes(code)

Donner le Résultat suivant :

```
> head(coords_rows$cos2)
```

	Dim 1	Dim 2
Brazil	0.9531155	0.04688446
Germany	0.9725034	0.02749662
Argentina	0.9555270	0.04447295
Italy	0.9582676	0.04173240
France	0.9506028	0.04939718
England	0.4985753	0.50142465

Figure 31:Affichage La qualite des points lignes

```
#Qualite de representation des lignes
fviz_ca_row(afc, col.row = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
             repel = TRUE)
```

Figure 32:Qualité de représentation des lignes (code)

Donne le résultat suivant :




Figure 33:Afficher le graphique des points lignes colorés

2.9 Graphique Des Points Colonnes

La fonction `get_ca_col()` [factoextra] est utilisée pour extraire les résultats pour les colonnes. Cette fonction renvoie une liste contenant les coordonnées, les cos2 et les contributions des colonnes :

```
# Obtenir les coordonnées des points colonnes
col <- get_ca_col(afc)
col
```

Figure 34::Obtenir les coordonnées des points colonnes (code)

Donner le résultat suivant :

```
> col
Correspondence Analysis - Results for columns
=====
  Name      Description
1 "$coord"  "Coordinates for the columns"
2 "$cos2"   "Cos2 for the columns"
3 "$contrib" "contributions of the columns"
4 "$inertia" "Inertia of the columns"
```

Figure 35:Correspondence Analysis - Results for columns

2.9.1 Les coordonnées des colonnes

Le code R ci-dessous affiche les coordonnées de chaque point colonnes pour chacune des dimensions :

```
> head(col$coord)
```

	Dim 1	Dim 2
Victoires	0.400801099	-0.1030333
matches nuls	-0.004900581	0.3692058
défaites	-0.395414732	-0.1063417

Figure 36: Les coordonnées des colonnes

Utilisez la fonction `fviz_ca_col()` [dans `factoextra`] pour visualiser uniquement les points lignes

```
# Afficher le graphique des points colonnes
fviz_ca_col(afc, col.col = "red")
```

Figure 37: le graphique des points colonnes (code)

Donne le résultat suivant :




Figure 38: la Représentation des colonnes

2.9.2 Qualité de représentation des colonnes

Le résultat de l'analyse montre que le tableau de contingence est bien représenté dans un espace de faibles dimensions en utilisant l'AFC. Les deux dimensions 1 et 2 sont suffisantes pour conserver 76,2% de l'inertie totale (variation) contenue dans les données. Cependant, tous les points ne sont pas aussi bien représentés dans les deux dimensions. Le $\cos^2$ mesure le degré d'association entre les lignes / colonnes et un axe particulier. Le $\cos^2$ des points colonnes peut être extrait comme suit :

```
> head(col$cos2)
               Dim 1      Dim 2
Victoires      0.9380122223 0.06198778
matches nuls    0.0001761496 0.99982385
défaites       0.9325512035 0.06744880
```

Figure 39:Qualité de représentation des colonnes

Les valeurs de cos2 sont comprises entre 0 et 1. La somme des cos2 pour les lignes sur toutes les dimensions de l'AFC est égale à 1.

```
#Qualite de representation des colonnes
fviz_ca_col(afc, col.col = "contrib",
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
  repel = TRUE)
```

Figure 40:Afficher le graphique des points colonnes (code)

Donne le résultat suivant :




Figure 41:Qualite de representation

3. Appliquer Par Python

3.1 Charger et afficher les données

```
#Importation des packages
import pandas as pd
from fanalysis.ca import CA
%matplotlib inline
import numpy
import matplotlib.pyplot as plt

# Chargement des données depuis un fichier Excel
data = pd.read_excel("C:\AnalyseD\donnees_nettoyees_Coupe_du_monde.xlsx")
print(data)
```

Figure 42: Importation des packages et des données (code)

On importe la librairie pandas pour charger les données, ainsi que la classe CA du package « fanalysis ».

	équipe national	Victoires	matches nuls	défaites
0	Brazil	76	19	19
1	Germany	68	21	23
2	Argentina	47	17	24
3	Italy	45	21	17
4	France	39	14	20
..	...	...	...	...
75	China	0	0	3
76	Canada	0	0	6
77	Haiti	0	0	3
78	DR Congo	0	0	3
79	El Salvador	0	0	6

[80 rows x 4 columns]

Figure 43: Les données affichées

3.2 Test de khi2

```
from scipy.stats import chi2_contingency

# Utilisation de la fonction chi2_contingency
chi2, pvalue, degrees, expected = chi2_contingency(data)

# Affichage des résultats
print("chi2 =", chi2)
print("degrés de liberté =", degrees)
print("p-valeur =", pvalue)
```

Figure 44: Test de khi2 (code)

L'exécution Donne le résultat suivant :

```
chi2 = 317.7893630902355
degrés de liberté = 158
p-valeur = 8.197981507066976e-13
```

Figure 45: Résultat du test khi2

La valeur de p étant très faible, nous rejetons l'hypothèse nulle. Cela indique qu'il existe une association significative entre les modalités en ligne et les modalités en colonne dans le tableau

de contingence analysé, mettant ainsi en évidence l'existence d'une liaison importante entre ces variables.

3.3 AFC en python

```
#lancer les calculs
afc = CA(row_labels=data.index,col_labels=data.columns)
afc.fit(data.values)
print(dir(afc))
```

Figure 46:Application de AFC (code)

L'exécution Donne le résultat suivant :

```
[ '__class__', '__delattr__', '__dict__', '__dir__', '__doc__', '__eq__', '__format__', '__ge__', '__getattr__', '__getstate__', '__gt__', '__hash__', '__init__', '__init_subclass__', '__le__', '__lt__', '__module__', '__ne__', '__new__', '__reduce__', '__reduce_ex__', '__repr__', '__setattr__', '__setstate__', '__sizeof__', '__sklearn_clone__', '__str__', '__subclasshook__', '__weakref__', '_build_request_for_signature', '_check_feature_names', '_check_n_features', '_compute_stats', '_compute_svd', '_get_default_requests', '_get_metadata_request', '_get_param_names', '_get_tags', '_more_tags', '_repr_html_', '_repr_html_inner', '_repr_mimebundle_', '_sklearn_auto_wrap_output_keys', '_validate_data', '_validate_params', 'c_', 'col_contrib_', 'col_coord_', 'col_cos2_', 'col_labels', 'col_labels_', 'col_labels_short_', 'col_topandas', 'eig_', 'fit', 'fit_transform', 'get_metadata_routing', 'get_params', 'mapping', 'mapping_col', 'mapping_row', 'model_', 'n_', 'n_components', 'n_components_', 'plot_col_contrib', 'plot_col_cos2', 'plot_eigenvalues', 'plot_row_contrib', 'plot_row_cos2', 'r_', 'row_contrib_', 'row_coord_', 'row_cos2_', 'row_labels', 'row_labels_', 'row_topandas', 'set_output', 'set_params', 'stats', 'transform']
```

Figure 47: Résultat de l'AFC

3.4 Les valeurs propres

L'évaluation des valeurs propres permet de déterminer le nombre d'axes à interpréter, où chaque valeur propre représente la quantité d'information résumée par chaque axe (dimension). Les valeurs propres et la répartition de la variance sur les différents axes peuvent être extraites à l'aide de la fonction `afc.eig_`.

```
#Affichage des valeur propres
print(afc.eig_)
```

Figure 48:les valeur propres(code)

L'exécution Donne le résultat suivant :

```
[[1.23482066e-01 3.86553645e-02]
 [7.61588891e+01 2.38411109e+01]
 [7.61588891e+01 1.00000000e+02]]
```

Figure 49: Affichage des valeurs propres

Pour afficher le graphique des valeurs propres en utilise la fonction `plot_eigenvalues` :

```
# Affichage graphique des valeurs propres
afc.plot_eigenvalues()
```

Figure 50: la fonction `plot_eigenvalues(code)`

L'exécution Donne le graphe suivant :




Figure 51: le graphe des valeurs propres

3.5 Résultat des lignes

3.5.1 Les Coordonnées des points lignes

```
# Coordonnées des points lignes
print(afc.row_coord_)
```

Figure 52: L'objet `row_coord` (code)

L'exécution Donne le résultat suivant :

```
[[-5.70521992e-01  1.26535995e-01]
 [-4.58802950e-01  7.71472175e-02]
 [-2.99593323e-01  6.46336397e-02]
 [-3.84386105e-01 -8.02159916e-02]
 [-2.98389097e-01  6.80196645e-02]
 [-1.84956148e-01 -1.85483897e-01]
 [-2.05091880e-01 -8.06183203e-02]
 [-3.93535444e-01 -8.39801931e-02]
 [-7.97106895e-02  8.04629164e-04]
 [-2.56409896e-02  5.96858915e-02]
 [-2.15571344e-03 -8.19329793e-02]
 [-7.83898581e-02 -3.72508304e-03]
 [ 2.05440176e-01 -6.85751692e-02]
 [ 8.87882231e-02  9.04376807e-02]
 [ 1.65805150e-01  1.18062105e-01]
```

Figure 53: Les coordonnées des points lignes

3.5.2 Les Contribution des points lignes



```
#Contribution des points lignes
print(afc.row_contrib_)
```

Figure 54: L'objet row_contrib_ (code)

L'exécution Donne le résultat suivant :

```
[1.53316774e+01 2.40916849e+00]
[9.74115535e+00 8.79817736e-01]
[3.26352523e+00 4.85214817e-01]
[5.06703022e+00 7.04910795e-01]
[2.68552256e+00 4.45785551e-01]
[1.04594610e+00 3.36030193e+00]
[1.16442569e+00 5.74746652e-01]
[3.51941466e+00 5.11977156e-01]
[1.54890644e-01 5.04170821e-05]
[1.38541467e-02 2.39799185e-01]
[9.79247062e-05 4.51878655e-01]
[1.14254237e-01 8.24173390e-04]
[1.04631403e+00 3.72408155e-01]
[1.59605132e-01 5.28967597e-01]
[3.97561314e-01 6.43918059e-01]
[6.40685258e-02 1.15031593e+00]
[3.07428993e-01 2.16027682e-01]
[2.22713001e-02 3.96084094e+00]
[0.00000000e+00 0.00000000e+00]
```

Figure 55: Les Contribution des points lignes

3.5.3 Les qualités des points lignes

```
#Cos2 des point colonnes
print(afc.row_cos2_)
```

Figure 56:L'objet row_cos2 (code)

L'exécution Donne le résultat suivant :

```
[9.53115538e-01 4.68844620e-02]
[9.72503384e-01 2.74966161e-02]
[9.55527049e-01 4.44729515e-02]
[9.58267600e-01 4.17323996e-02]
[9.50602819e-01 4.93971812e-02]
[4.98575347e-01 5.01424653e-01]
[8.66164604e-01 1.33835396e-01]
[9.56444231e-01 4.35557687e-02]
[9.99898114e-01 1.01885917e-04]
[1.55801238e-01 8.44198762e-01]
[6.91773667e-04 9.99308226e-01]
[9.97746941e-01 2.25305901e-03]
[8.99749898e-01 1.00250102e-01]
[4.90797547e-01 5.09202453e-01]
[6.63557457e-01 3.36442543e-01]
```

Figure 57:Les qualites des points lignes

3.6 Résultat des colonnes

3.6.1 Les Coordonnées des points colonnes

```
#Contribution des points colonnes
print(afc.col_coord_)
```

Figure 58:L'objet col_coord_ (code)

L'exécution Donne le résultat suivant :

```
[[-0.4008011  0.10303332]
 [ 0.00490058 -0.36920577]
 [ 0.39541473  0.1063417  ]]
```

Figure 59: : Les coordonnes des points lignes

3.6.2 Les Contributions des points colonnes

```
#Contribution des points colonnes
print(afc.col_contrib_)
```

Figure 60: L'objet col_contrib_ (code)

L'exécution Donne le résultat suivant :

```
[[5.05105975e+01 1.06628719e+01]
 [4.29658121e-03 7.79038667e+01]
 [4.94851059e+01 1.14332615e+01]]
```

Figure 61: Les contributions des points colonnes

3.6.3 Les qualités des points colonnes

```
#Cos2 des point colonnes
print(afc.col_cos2_)
```

Figure 62: Les qualités des points colonnes (code)

L'exécution Donne le résultat suivant :

```
[[9.38012222e-01 6.19877777e-02]
 [1.76149582e-04 9.99823850e-01]
 [9.32551204e-01 6.74487965e-02]]
```

Figure 63: Les qualités des points colonnes

3.7 Représentation des points de lignes et de colonnes

```
#representation simultanee
afc.mapping(num_x_axis=1,num_y_axis=2,figsize=(10,10))
```

Figure 64: la fonction mapping() (code)

L'exécution Donne le graphe suivant :




Figure 65: Représentation simultanée

4. Appliquer par Excell

4.1 L'utilisation d'Excel

Une fois XLSTAT ouvert, sélectionnez la fonctionnalité XLSTAT / Analyse des données / Analyse des correspondances.




Figure 66: L'UTILISATION DE EXCEL

- Après avoir cliqué sur le bouton, la fenêtre de dialogue pour l'Analyse des Correspondances s'affiche.




Figure 67: la boîte de dialogue CA

- Sur l'onglet "Général", choisissez le tableau complet dans la feuille Excel. Si vos données sont disposées dans un tableau de contingence, comme illustré ici, optez pour le format de tableau à double entrée. Si vos données sont organisées dans un tableau Individus/Variables, sélectionnez plutôt l'option Tableau Observations/Variables.
- Si les libellés des catégories pour chaque variable sont présents à la fois dans les lignes et les colonnes, assurez-vous que la case "Libellés inclus" est activée.
- Avant de commencer l'interprétation introduisons la notion de profil. L'Analyse des Correspondances est basée sur l'analyse des profils. Un profil est un ensemble de fréquences divisées par leur total, c'est-à-dire les fréquences relatives. En d'autres termes, un profil reflète la façon dont la catégorie d'une variable change en fonction des catégories de l'autre variable.

4.2 Test de khi2

Test of independence between the rows and the columns:	
Chi-square (Observed value)	317,789
Chi-square (Critical value)	188,332
DF	158
p-value	<0,0001
alpha	0,05

Figure 68: Test de khi2

Le premier résultat affiché est le test d'indépendance entre les lignes et les colonnes, basé sur une statistique du chi carré. Si la valeur du chi carré observée est supérieure à la valeur critique, et si la valeur de p est inférieure au niveau alpha choisi, alors on peut conclure que les lignes et les colonnes du tableau sont significativement associées. Dans cette étude, il est hautement probable que des différences significatives existent entre les équipes nationales en termes de leurs performances.

4.3 Les valeurs propres

Total inertia:	0,162	
Eigenvalues and percentages of inertia:		
	F1	F2
Eigenvalue	0,123	0,039
Inertia %	76,159	23,841
Cumulative %	76,159	100,000

Figure 69: Les valeurs propres par Excel

Les valeurs propres correspondent à la variance extraite par chaque facteur (dimension). La qualité de l'analyse peut être évaluée en consultant le tableau des valeurs propres ou le scree plot correspondant. Si la somme des deux (ou quelques) premières valeurs propres est proche du total représenté, alors la qualité de l'analyse est très élevée.

4.4 Scree plot




Figure 70: Scree plot

4.5 Résultats pour lignes

4.5.1 Poids, distances et distances quadratiques à l'origine, inerties et inerties relatives

Results for the rows:					
Weights, distances and squared distances to the origin, inertias and relative inertias (rows):					
	Weight (relative)	Distance	Sq-Distance	Inertia	Inertia relative
Brazil	0,058	0,584	0,342	0,020	0,123
Germany	0,057	0,465	0,216	0,012	0,076
Argentina	0,045	0,306	0,094	0,004	0,026
Italy	0,042	0,393	0,154	0,007	0,040
France	0,037	0,306	0,094	0,003	0,022
England	0,038	0,262	0,069	0,003	0,016
Spain	0,034	0,220	0,049	0,002	0,010
Netherlands	0,028	0,402	0,162	0,005	0,028
Uruguay	0,030	0,080	0,006	0,000	0,001
Belgium	0,026	0,065	0,004	0,000	0,001
Sweden	0,026	0,082	0,007	0,000	0,001
Russia	0,023	0,078	0,006	0,000	0,001
Mexico	0,031	0,217	0,047	0,001	0,009
Serbia	0,025	0,127	0,016	0,000	0,002
Portugal	0,018	0,204	0,041	0,001	0,005
Poland	0,019	0,164	0,027	0,001	0,003
Switzerland	0,021	0,149	0,022	0,000	0,003
Hungary	0,016	0,309	0,095	0,002	0,010
Croatia	0,015	0,189	0,036	0,001	0,003
Slovakia	0,018	0,227	0,052	0,001	0,006
Czech Republic	0,017	0,214	0,046	0,001	0,005
Austria	0,015	0,203	0,041	0,001	0,004
Chile	0,017	0,136	0,019	0,000	0,002

Figure 71: la Distance et le poids pour les lignes

Le tableau présente les poids, les distances et les carrés des distances par rapport à l'origine, les inerties et les inerties relatives des lignes et des colonnes, ainsi que les distances et les poids pour les lignes des proportions marginales utilisées pour pondérer les profils de points lors du calcul des distances. Une distance plus grande par rapport à l'origine indique une dissemblance accrue entre le profil de catégorie et le profil moyen, ce qui signifie que la catégorie contribue davantage à la dépendance entre les deux variables.

Les équipes nationales de l'Uruguay, de la Belgique, de la Suède, de la Russie, de la Roumanie et de l'Ukraine ont la distance la plus courte à l'origine, indiquant que ces profils de groupe sont proches du profil moyen.

4.5.2 Les coordonnées des lignes

Results for the rows:					
Weights, distances and squared distances to the origin, inertias and relative inertias (rows):					
	Weight (relative)	Distance	Sq-Distance	Inertia	Inertia relative
Brazil	0,058	0,584	0,342	0,020	0,123
Germany	0,057	0,465	0,216	0,012	0,076
Argentina	0,045	0,306	0,094	0,004	0,026
Italy	0,042	0,393	0,154	0,007	0,040
France	0,037	0,306	0,094	0,003	0,022
England	0,038	0,262	0,069	0,003	0,016
Spain	0,034	0,220	0,049	0,002	0,010
Netherlands	0,028	0,402	0,162	0,005	0,028
Uruguay	0,030	0,080	0,006	0,000	0,001
Belgium	0,026	0,065	0,004	0,000	0,001
Sweden	0,026	0,082	0,007	0,000	0,001
Russia	0,023	0,078	0,006	0,000	0,001
Mexico	0,031	0,217	0,047	0,001	0,009
Serbia	0,025	0,127	0,016	0,000	0,002
Portugal	0,018	0,204	0,041	0,001	0,005
Poland	0,019	0,164	0,027	0,001	0,003
Switzerland	0,021	0,149	0,022	0,000	0,003
Hungary	0,016	0,309	0,095	0,002	0,010
Croatia	0,015	0,189	0,036	0,001	0,003
Slovakia	0,018	0,227	0,052	0,001	0,006
Czech Republic	0,017	0,214	0,046	0,001	0,005
Austria	0,015	0,203	0,041	0,001	0,004
Chile	0,017	0,136	0,019	0,000	0,002

Figure 72: Résultats pour les lignes

Principal coordinates (rows):		
	F1	F2
Brazil	0,571	-0,127
Germany	0,459	-0,077
Argentina	0,300	-0,065
Italy	0,384	0,080
France	0,298	-0,068
England	0,185	0,185
Spain	0,205	0,081
Netherlands	0,394	0,084
Uruguay	0,080	-0,001
Belgium	0,026	-0,060
Sweden	0,002	0,082
Russia	0,078	0,004
Mexico	-0,205	0,069
Serbia	-0,089	-0,090
Portugal	0,166	-0,118
Poland	0,064	-0,151
Switzerland	-0,135	-0,063
Hungary	0,041	-0,306
Croatia	0,153	0,111
Slovakia	-0,185	-0,132
Czech Republic	-0,133	-0,168
Austria	-0,034	-0,200
Chile	-0,134	-0,022

Figure 73: Les coordonnées des lignes

Les coordonnées principales et les coordonnées standard des lignes (colonnes respectivement) sont présentées. Les coordonnées standard sont obtenues en divisant les coordonnées principales par la racine carrée de la valeur propre du facteur correspondant. Chaque facteur a une somme pondérée des carrés des coordonnées standard égale à 1.

4.5.3 Les contributions des lignes

Contributions (rows):				
	Weight (relative)	F1	F2	
Brazil	0,058	0,153	0,024	
Germany	0,057	0,097	0,009	
Argentina	0,045	0,033	0,005	
Italy	0,042	0,051	0,007	
France	0,037	0,027	0,004	
England	0,038	0,010	0,034	
Spain	0,034	0,012	0,006	
Netherlands	0,028	0,035	0,005	
Uruguay	0,030	0,002	0,000	
Belgium	0,026	0,000	0,002	
Sweden	0,026	0,000	0,005	
Russia	0,023	0,001	0,000	
Mexico	0,031	0,010	0,004	
Serbia	0,025	0,002	0,005	
Portugal	0,018	0,004	0,006	
Poland	0,019	0,001	0,012	
Switzerland	0,021	0,003	0,002	
Hungary	0,016	0,000	0,040	
Croatia	0,015	0,003	0,005	
Slovakia	0,018	0,005	0,008	
Czech Republic	0,017	0,002	0,012	
Austria	0,015	0,000	0,015	
Chile	0,017	0,002	0,000	

Figure 74:Contributions (lignes)

Voici un tableau des contributions des lignes (colonnes respectivement). Les contributions correspondent à l'importance de chaque catégorie pour chaque facteur (dimension). La somme des contributions est égale à 1 pour chaque facteur. En règle générale, si la contribution est supérieure à $1/I$, 1 étant le nombre de lignes (respectivement $1/J$ avec J le nombre de colonnes), la catégorie est importante pour le facteur donné. Notre étude met en évidence le Brésil comme le principal contributeur dans les catégories F1, suivi de près par l'Allemagne dans F1 et l'Angleterre dans F2. Les contributions des autres pays varient considérablement, mais en règle générale, les grandes nations du football se démarquent par des contributions plus significatives que les autres.

4.6 Résultat pour les colonnes

4.6.1 Poids, distances et carrés des distances à l'origine, inerties et inerties relatives (colonnes)

Results for the columns:					
Weights, distances and squared distances to the origin, inertias and relative inertias (columns):					
	Weight (relative)	Distance	Sq-Distance	Inertia	Inertia relative
Victoires	0,388	0,414	0,171	0,066	0,410
matches nuls	0,221	0,369	0,136	0,030	0,186
défaites	0,391	0,409	0,168	0,066	0,404

Figure 75:La distance et le poids des colonnes

4.6.2 Les coordonnées des colonnes

Les coordonnées principales et les coordonnées standard des colonnes (lignes respectivement) sont également affichées. Les coordonnées standard sont les coordonnées principales divisées

par la racine carrée de la valeur propre du facteur correspondant. La somme des carrés pondérée des coordonnées standard est égale à 1 pour chaque facteur.

Principal coordinates (columns):		
	F1	F2
Victoires	0,401	-0,103
matches nuls	-0,005	0,369
défaites	-0,395	-0,106
Standard coordinates (columns):		
	F1	F2
Victoires	1,141	-0,524
matches nuls	-0,014	1,878
défaites	-1,125	-0,541

Figure 76: Les coordonnées des colonnes

4.6.3 Les contributions des colonnes

Contributions (columns):			
	Weight (relative)	F1	F2
Victoires	0,388	0,505	0,107
matches nuls	0,221	0,000	0,779
défaites	0,391	0,495	0,114

Figure 77: Les contributions des colonnes

Voici un tableau des contributions des colonnes (lignes respectivement). Les contributions correspondent à l'importance de chaque catégorie pour chaque facteur (dimension). La somme des contributions est égale à 1 pour chaque facteur. En règle générale, si la contribution est supérieure à $1/I$, I étant le nombre de lignes (respectivement $1/J$ avec J le nombre de colonnes), la catégorie est importante pour le facteur donné.

Notre étude met en évidence que les victoires ont le poids relatif le plus élevé parmi les résultats, suivies des défaites, tandis que les matches nuls ont le poids relatif le plus faible.

4.7 Graphique symétrique





Figure 78: Graphique symétrique

Les différentes cartes sont d'abord affichées en utilisant le tracé symétrique des lignes et des colonnes, également connu sous le nom de tracé français, qui est le plus couramment utilisé. Dans cet affichage, les profils de lignes et les profils de colonnes sont superposés en coordonnées principales. Cette méthode offre une grande praticité car les points de lignes et de colonnes sont distribués de manière égale. De plus, la distance entre les points de lignes et de colonnes se rapproche de la distance du chi carré interlignes et inter-colonnes.

Interprétation

Dans ce chapitre, nous explorerons la performance des équipes nationales de football engagées dans la Coupe du Monde jusqu'à l'année 2022. En visualisant et en interprétant les données, nous serons en mesure d'analyser l'efficacité de ces équipes, de déterminer les similitudes dans leurs performances, et d'identifier les nations les plus performantes dans cette compétition.

1. Compréhension des axes



Nous constatons que le premier axe explique 78,7% de la variance totale, ce qui indique qu'il englobe la majorité des équipes. Le deuxième axe, quant à lui, représente 21,3% de la variance totale. Ensemble, ces deux axes capturent 100% de la variance, ce qui signifie qu'ils fournissent une représentation complète de la distribution des données.

- **La première dimension**, qui explique 78.7% de la variance, met en lumière les différences générales de performance entre les équipes. Les équipes positionnées avec des valeurs positives élevées sur cette dimension ont tendance à accumuler davantage de victoires et moins de défaites, tandis que celles avec des valeurs négatives élevées peuvent présenter plus de défaites et moins de victoires. Cette dimension permet d'identifier des groupes d'équipes distingués en termes de résultats de matchs.
- **La deuxième dimension**, bien que moins influente avec une explication de 21.3% de la variance, reste significative. Elle révèle des caractéristiques spécifiques des performances dans les matchs qui peuvent différer de celles observées dans la première dimension. L'examen des positions des équipes sur cette dimension permet d'identifier d'autres distinctions, possiblement liées à des aspects tels que les matchs nuls ou d'autres statistiques spécifiques.

2. Contribution des lignes




Figure 79: Contribution des lignes

Lorsque nous examinons l'axe 1, nous remarquons une contribution significative du Brésil et de l'Allemagne, les distinguant des autres équipes. En revanche, en nous concentrant sur l'axe 2, nous observons une contribution notable de la République d'Irlande, la distinguant également des autres équipes.

3. Contribution des colonnes





Figure 80: Contribution des colonnes

La catégorie "Victoires" contribue de manière significative sur le 1^{er} axe, tandis que les catégories "Matches nuls" et "Défaites" ont des contributions moins marquées sur cet axe. En


ce qui concerne l'axe 2, la catégorie "Matches nuls" présente une contribution légèrement plus élevée par rapport aux autres catégories.

4. Qualité de représentation des lignes




Un cosinus carré ($\cos^2$) proche de 1 indique une représentation efficace des équipes selon les axes correspondants. Cela suggère que les caractéristiques des équipes sont bien encapsulées par ces dimensions d'analyse. Dans ce contexte spécifique, cela signifie que 78.7% des équipes sont bien représentées sur le premier axe, tandis que les autres sont correctement représentées sur le deuxième axe.

5. Qualité de représentation des colonnes



Les résultats montrent que les dimensions (axes) de l'analyse représentent bien deux aspects différents des performances des équipes : le premier axe représente la tendance générale des équipes à remporter des matchs ou subir des défaites, tandis que le deuxième axe représente la tendance à faire match nul. Ces axes capturent efficacement les variations dans les performances des équipes.

6. Graphe des points de lignes et de colonnes



- Conjonction :
 1. La majorité des matchs joués par l'Afrique du Sud, Cuba et Wales se terminent par des matchs nuls.
 2. La majorité des matchs joués par le Brésil, l'Allemagne et la France se terminent par des victoires.
 3. La majorité des matchs joués par le Pérou, Ghana et Nigeria se terminent par des défaites.
- Quadrature :
 1. Les autres matchs joués par le Brésil, l'Allemagne et la France qui ne se terminent pas par des victoires se terminent majoritairement par des défaites.
 2. Le reste des matchs joués par le Pérou, le Ghana et le Nigeria qui ne se terminent pas par des défaites se terminent majoritairement par des victoires.
- Opposition :

Une opposition entre les victoires, les défaites et les matchs nuls. Par exemple, certaines équipes comme le Brésil et l'Allemagne ont un nombre élevé de victoires par rapport à un nombre relativement faible de matchs nuls, suggérant qu'elles ont tendance à gagner plus souvent qu'à faire match nul. En revanche, d'autres équipes comme l'Égypte ou le Canada affichent un nombre plus élevé de défaites par rapport aux

victoires et aux matchs nuls, indiquant une tendance à perdre plus souvent qu'à obtenir un résultat équivalent.

Conclusion

En conclusion, l'utilisation conjointe de R, Python et Excel pour mener à bien l'Analyse des Correspondances Factorielle a été essentielle dans notre étude sur les performances des équipes nationales de football à la Coupe du Monde. Bien que Python offre une flexibilité et une polyvalence appréciables, j'ai préféré utiliser R en raison de sa richesse en packages statistiques et de sa convivialité pour l'analyse de données complexes. De plus, R étant open-source, il offre une solution économique par rapport à Excel qui est payant.

Les résultats de l'analyse ont permis de mettre en évidence des tendances significatives dans les performances des équipes, en identifiant des schémas sous-jacents et des distinctions clés entre les différentes nations participantes. Cette approche analytique a fourni des insights précieux pour évaluer et comparer la performance des équipes tout au long de la compétition, offrant ainsi des perspectives utiles pour des applications pratiques dans le domaine du sport.